

# Presentación Práctica - Reconocimiento de Señales de Tráfico con Aprendizaje Automático

Lucía Sánchez

## 1 Introducción

Este proyecto tiene como objetivo el desarrollo de un sistema de aprendizaje automático para la clasificación de señales de tráfico utilizando el dataset *German Traffic Sign (GTS)*. A lo largo del proyecto, se implementaron diversos enfoques de aprendizaje automático, que incluyeron tanto técnicas clásicas como redes neuronales convolucionales (CNN). Además de la implementación de la CNN para el reconocimiento de señales de tráfico, se abordaron procesos de preprocesamiento de datos, balanceo de clases, optimización de modelos y evaluación de su rendimiento, asegurando la clasificación correcta de las señales en 43 clases distintas.

## 2 Estructura del Proyecto

El proyecto está organizado en varias carpetas y archivos clave, facilitando la ejecución y gestión del mismo. A continuación, se describe la estructura y la función de cada componente:

- **modelo\_colab:** Contiene los cuadernos de Google Colab donde se desarrollaron y entrenaron los modelos. Los cuadernos permiten reproducir el proceso de entrenamiento y evaluación, y están organizados para facilitar la ejecución en un entorno basado en la nube.
- **archivos\_csv:** Almacena los archivos CSV generados durante el proceso de entrenamiento y validación. Estos archivos contienen las etiquetas de las clases y los valores correspondientes a las imágenes procesadas, usados por el modelo en el entrenamiento.

- **cnn.pth:** Este archivo contiene el modelo entrenado, guardado en formato de PyTorch. Sirve para cargar el modelo entrenado y realizar predicciones sobre nuevas imágenes de señales de tráfico.
- **models:** Esta carpeta incluye los archivos relacionados con la definición de la arquitectura del modelo. Contiene los scripts y funciones para la implementación de la red neuronal convolucional (CNN) y otros modelos empleados en el proyecto.
- **utils:** Incluye archivos auxiliares para el preprocesamiento de datos, el balanceo de clases, la visualización de resultados, y otros procesos necesarios durante el entrenamiento y evaluación del modelo.

En la carpeta principal del proyecto, se encuentran los archivos `cnn.pth`, `models`, `utils`, y las carpetas `modelo_colab` y `archivos_csv`, organizados para separar las funcionalidades del sistema y permitir una fácil navegación.

### 3 Metodología

El enfoque del proyecto fue el siguiente:

- **Preprocesamiento de Datos:** Se implementaron funciones para el procesamiento y carga de las imágenes del dataset, así como técnicas de *data augmentation* para mejorar la generalización del modelo. Además, se abordó el problema del desbalance de clases mediante técnicas de balanceo que garantizan que el modelo no favorezca clases mayoritarias.
- **Modelo de Aprendizaje Automático:** La arquitectura principal del modelo es una red neuronal convolucional (CNN), que es eficaz para la clasificación de imágenes. La CNN está formada por varias capas convolucionales que extraen características importantes de las imágenes. Estas características son procesadas por capas de pooling y densas, para luego realizar la clasificación de las señales en 43 clases distintas.
- **Optimización:** Durante el entrenamiento, se utilizó la técnica de *data augmentation* para generar más datos a partir de las imágenes originales y mejorar la robustez del modelo. Además, se aplicaron técnicas de ajuste de hiperparámetros, como el aprendizaje con descenso de gradiente y la selección del mejor optimizador para mejorar la precisión de la clasificación.

- **Evaluación del Modelo:** El modelo fue evaluado utilizando un conjunto de datos de prueba, con el fin de medir su rendimiento en condiciones no vistas durante el entrenamiento. Para ello, se utilizó la precisión como métrica principal, y se analizaron los resultados obtenidos mediante matrices de confusión y otras métricas de clasificación.

## 4 Objetivos del Proyecto

El principal objetivo de este proyecto fue desarrollar un sistema de aprendizaje automático capaz de clasificar señales de tráfico de acuerdo a 43 clases diferentes. A través de la implementación de la CNN y el uso de técnicas avanzadas de preprocesamiento y balanceo de clases, el proyecto buscó obtener un modelo con alta precisión, capaz de generalizar bien a nuevas imágenes. Además, se procuró que el sistema fuera eficiente en términos de tiempo de procesamiento, permitiendo su uso en aplicaciones prácticas de clasificación de señales de tráfico.

## 5 Resultados y Conclusiones

Este proyecto demuestra la efectividad de las redes neuronales convolucionales para la tarea de clasificación de imágenes. A través de la implementación de técnicas de *data augmentation* y el balanceo de clases, se mejoró la precisión del modelo a pesar de los desafíos del dataset desbalanceado.

Además, el enfoque modular del proyecto, con su clara organización de carpetas y scripts, permite la fácil reproducción de los experimentos y la reutilización de los componentes para futuros trabajos. El modelo entrenado, disponible en el archivo `cnn.pth`, se puede utilizar para realizar predicciones sobre nuevas imágenes de señales de tráfico.

En conclusión, este proyecto ha sido exitoso en demostrar que las redes neuronales convolucionales, junto con un adecuado preprocesamiento de datos y técnicas de optimización, pueden clasificar con precisión señales de tráfico, siendo una base sólida para aplicaciones en entornos reales de tráfico inteligente y sistemas automatizados de transporte.